
Caracterización de Grafos obtenidos de mapas de actividad cerebral

Anonymous Author(s)

Affiliation

Address

email

Abstract

1 Estudiamos matrices de adyacencia de actividad cerebral obtenidas de individuos
2 sanos durante distintos estados de vigilia y sueño para explorar las características
3 de los grafos generados. Observamos diferencias significativas tanto en topología
4 de dichos grafos, como en intensidad de actividad de las zonas exploradas. Los
5 resultados respaldan el uso de este tipo de tecnologías en la exploración de la
6 actividad cerebral bajo condiciones diversas.

7 1 Objetivos

8 Nos proponemos estudiar y caracterizar los grafos generados mediante métodos computacionales
9 a partir de mapas de actividad cerebral convertidos en matrices de Adyacencia. Estudiaremos
10 la topología de los grafos obtenidos y calcularemos parámetros típicos sometiendo a los datos a
11 distintas transformaciones con el fin de identificar técnicas y procedimientos que resulten útiles en la
12 caracterización de dichos grafos.

13 2 Materiales y Métodos

14 Utilizamos los datos obtenidos por el grupo de estudio de Tagliazucchi y colaboradores (2013).
15 Remitimos al lector al trabajo mencionado para una descripción detallada de los métodos utilizados
16 para las mediciones y los criterios de selección de los sujetos.

17 2.1 Datos

18 El conjunto de datos utilizado contiene información obtenida de 18 sujetos. Para cada uno de ellos se
19 obtuvo 4 registros que corresponden a diferentes estados:

- 20 1. Vigilia
- 21 2. Sueño NREM - Fase 1
- 22 3. Sueño NREM - Fase 2
- 23 4. Sueño NREM - Fase 3

24 2.2 Procesamiento

25 Procesamos los archivos obtenidos utilizando Python 3.10.16 y una colección de bibliotecas de
26 funciones de código abierto. La siguiente es una lista exhaustiva de las mismas:

- 27 1. Matplotlib 3.10.1

- 28 2. Seaborn 0.13.2
- 29 3. NumPy 2.2.4
- 30 4. Pandas 2.2.3
- 31 5. NetworkX 3.4.2

32 El procesamiento se realizó en una computadora Apple modelo MCYT4T/A. La instalación de Python
33 es la instalación standard utilizando PyEnv y Virtual Environments con Venv. El código se ejecutó en
34 un notebook de Jupyter Notebooks.

35 **3 Procedimiento y Resultados**

36 **3.1 Obtención de Matriz de Adyacencia Pesada y Gráficación**

37 Tomando como ejemplo el Sujeto 2 en estado de Vigilia, cargamos el archivo CSV correspondiente
38 (DataSujetos/W-suj2.csv) y mediante el método 'values()' de la clase Pandas DataFrame obtenemos
39 un Numpy Array. Usando diferencia de matrices restamos una diagonal de unos para evitar datos de
40 autonconexión y obtenemos la matriz de adyacencia pesada. Esta secuencia está encapsulada en una
41 función ya que es el punto de partida para todos los análisis posteriores. Para el Sujeto mencionado
42 graficamos la matriz de adyacencia pesada como un heatmap como puede observarse en la Figura 1.

43 **3.2 Binarización**

44 Dada una densidad de enlaces definida como 0.08, obtenemos el valor umbral necesario para binarizar
45 la matriz. El valor de umbral obtenido es: 0.7797 A partir de este valor fabricamos una matriz
46 booleana que tiene valor True para aquellos enlaces cuyo peso es igual o superior al valor umbral,
47 False en caso contrario. La matriz resultante se representa en un heatmap.

48 **3.3 Obtención del grafo**

49 Utilizando la matriz binarizada y las coordenadas (y,z) para construir el layout, representamos el
50 grafo, lo que, dada la alta densidad de enlaces, requiere optimizar algunos parámetros de gráficación
51 para que sea visible. El resultado se muestra en la Figura 2.

52 **3.4 Caracterización del Grafo**

53 Utilizando la función 'is_connected()' de NetworkX determinamos que el Grafo no es conexo. Por
54 este motivo no puede calcularse la distancia media entre nodos. Podemos en cambio, calcular la
55 distancia media entre nodos en la componente gigante, la cual resulta ser: 3.891 La componente
56 gigante tiene 92 nodos con un diámetro de 11. Las componentes conexas y su distancia media se
57 muestran en la Tabla 1.

58 La eficiencia global del Grafo resulta ser 0.245 La eficiencia global de la componente gigante es
59 0.388

60 **3.5 Distribución de Grados**

61 Utilizando el mismo grafo de las secciones precedentes, vamos a caracterizar la distribución de
62 grados. El grado promedio de la red es 9.207 El nodo de mayor grado es el Nodo 0 y su grado es: 30
63 La figura 3 muestra un histograma de distribución de grados.

64 **3.6 Coeficiente de Clustering**

65 Por último, calculamos el Coeficiente de Clustering promedio, el cual resulta ser: 0.544 La figura
66 4 muestra el grafo representado con los nodos coloreados en una escala de color que muestra su
67 coeficiente de clustering.




Figure 1: Matriz de Adyacencia pesada para el Sujeto 02 en estado de vigilia




Figure 2: Grafo de la Matriz de Adyacencia Binarizada

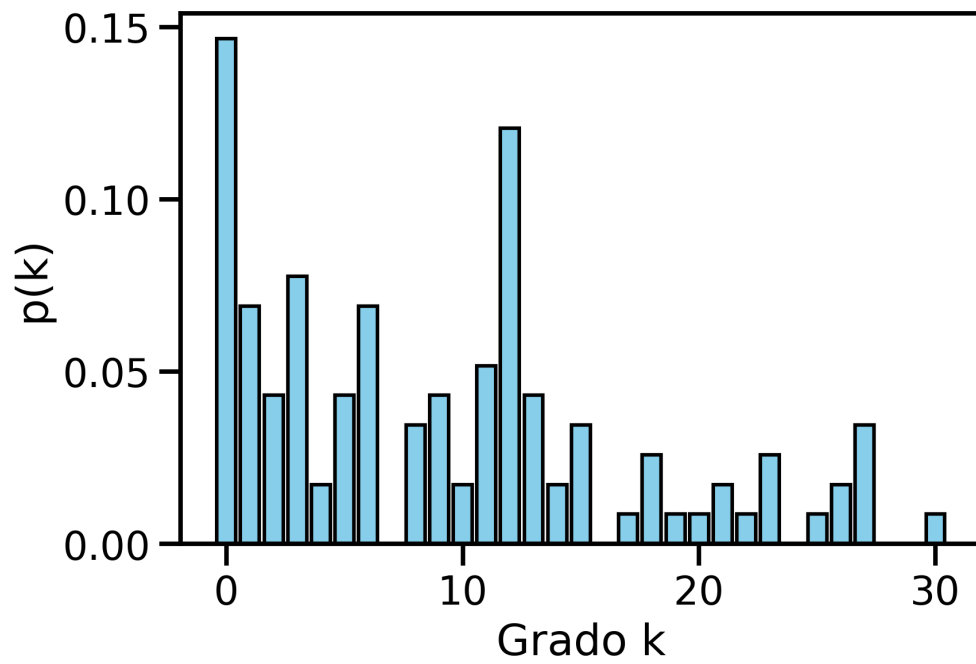


Figure 3: Distribución Normalizada de Grados en la Matriz de Adyacencia Binarizada




Figure 4: Grafo con escala de colores según el Coeficiente de Clustering

Table 1: Distancia Media de Componentes Conexas

Descripción	No. Nodos	Dist. Media
Comp. Gigante	92	3.89
Comp. Conexa 01	5	1.60
Comp. Conexa 02	2	1.00

68 4 Conclusiones

69 Los resultados mostrados indican que los grafos obtenidos de matrices de adyacencia, binarizados de
70 acuerdo a criterios de densidad de enlaces podrían ser útiles en el análisis de la actividad cerebral de
71 individuos en diversos estados de vigilia.

72 5 Reconocimientos

73 Este trabajo se realizó utilizando fondos y recursos auto-gestionados, y las horas improbables de
74 feriados, fines de semana y extra-laborales.

75 Referencias

- 76 [1] Enzo Tagliazucchi, Frederic Von Wegner, Astrid Morzelewski, Verena Brodbeck, Sergey Borisov, Kolja
77 Jahnke, and Helmut Laufs. Large-scale brain functional modularity is reflected in slow electroencephalographic
78 rhythms across the human non-rapid eye movement sleep cycle. *Neuroimage*, 70:327–339, 2013.
- 79 [2] Borges, J.L. Obras Completas (1996) Emecé Editores
- 80 [3] Borch, M. Omaggio a Firenze (2021) Tethys
- 81 [3] Hasselmo, M.E., Schnell, E. & Barkai, E. (1995) Dynamics of learning and recall at excitatory recurrent
82 synapses and cholinergic modulation in rat hippocampal region CA3. *Journal of Neuroscience* **15**(7):5249-5262.